METODOLOGÍA DE LA INVESTIGACIÓN

Metodología TDSP

Fabiola López Velázquez, Jorge Luis Ortiz Libreros, Joshua Iván Olivares Blanco

Aplicación de la Metodología TDSP para la Predicción del Riesgo de Diabetes

Nuestro análisis es sobre la base de datos de diabetes que tiene 15,000 registros usando la metodología TDSP, proporcionando una estructura estandarizada, abarcando desde la adquisición hasta la implementación.

Definimos roles dentro de este trabajo para poder repartirnos fases. Para estructurar operativamente el proyecto bajo la metodología TDSP, nosotros que somos 3 dentro del equipo, asumimos responsabilidades específicas durante el ciclo de vida del modelo de diabetes:

- **Joshua Iván Olivares Blanco – Líder del Proyecto (Project Lead):** Encargado de la gestión metodológica y documental. La tarea fue estructurar el proyecto bajo las normativas TDSP, redactar las justificaciones para las fases de Comprensión del Negocio y Aceptación del Cliente, y consolidar los descubrimientos analíticos en el reporte final de Metodología de la Investigación.
- **Fabiola López Velázquez – Científica de Datos (Data Scientist):** Encargada del modelado analítico y matemático. Su ocupación consistió en ajustar el algoritmo de árbol de decisión multiclase, determinar el parámetro de complejidad óptimo mediante validación cruzada y extraer las métricas de evaluación (Accuracy, índice Kappa y sensibilidad por clase).
- **Jorge Luis Ortiz Libreros – Ingeniero de Datos (Data Engineer / Architect):** Responsable de la infraestructura y preparación de la información. Se ocupó del tratamiento de la base de datos (asignación de categoría "Unknown" a los valores faltantes, eliminación de variables sin varianza predictiva), la partición estratificada de la muestra y la serialización del modelo para la fase de implementación.

También utilizamos R para poder generar ayudas visuales con gráficas, dentro de este mismo usamos una función que generara y guardara los gráficos hechos con el código en una carpeta fuera de R llamada docs que se guarda en el escritorio. Principalmente para facilitar su manipulación y asegurar guardarlas.

1. Comprensión del Negocio (Business Understanding)

- **Planteamiento del problema:** La evaluación del riesgo de padecer diabetes es un proceso complejo que requiere analizar múltiples variables simultáneamente. Existe la necesidad metodológica de una herramienta automatizada y basada en evidencia para apoyar el diagnóstico clínico.
- **Objetivo de la Investigación:** Desarrollar e implementar un modelo predictivo de clasificación supervisada multiclase para estratificar el riesgo de diabetes

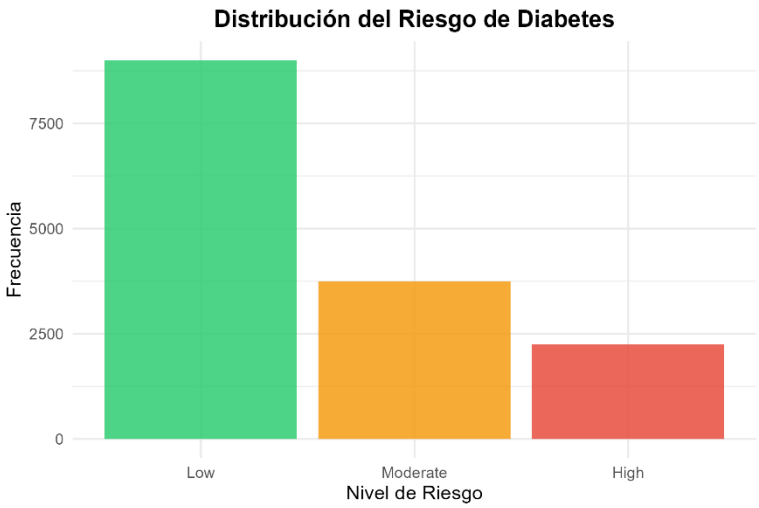
en tres niveles (Low, Moderate y High), para garantizar la interpretabilidad de las reglas de decisión clínica.

- **Contexto clínico:** El modelo busca apoyar la toma de decisiones utilizando características demográficas y mediciones clínicas.

2. Adquisición y Comprensión de Datos (Data Acquisition and Understanding)

Exploración de la Base de Datos

- Nuestra base contiene 15,000 registros
- Detectamos valores faltantes (NA) los cuales fueron categorizados como "Unknown" para preservar el volumen de datos.
- También eliminamos la variable patient_id al no poseer valor predictivo.



El estudio se basó en una muestra de 15,000 observaciones depuradas. Se analizó la distribución de la variable objetivo, encontrando una prevalencia del **60%** para riesgo Low, **25%** para Moderate y **15%** para High.

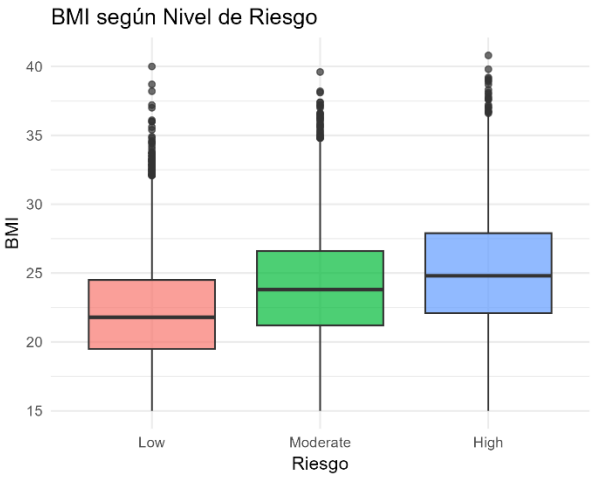
Tratamiento de Datos:

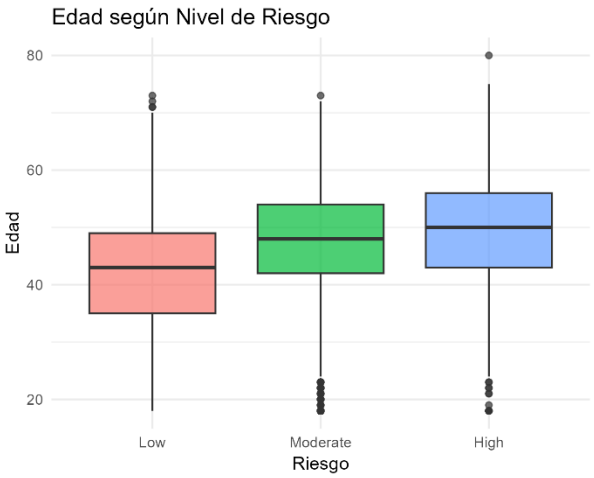
Para mantener la integridad y el volumen de la muestra, no se eliminaron las observaciones con valores faltantes en variables de estilo de vida (smoking_status, alcohol_consumption, income_bracket). Ya que mejor optamos por agruparlas en una nueva categoría llamada “Unknown", permitiendo que el algoritmo interprete la ausencia de información como un patrón.

Decidiendo que la variable patient_id fuera descartada por carecer de varianza predictiva.

Análisis Visual y Justificación de los Datos:

La exploración multivariada demostró que, aunque la mediana del Índice de Masa Corporal (BMI) y la edad aumentan conforme se agrava el riesgo, existe un traslape estadístico significativo entre las categorías. Y este hallazgo visual justifica la insuficiencia de métodos de corte simples y exige la aplicación de algoritmos de Machine Learning.

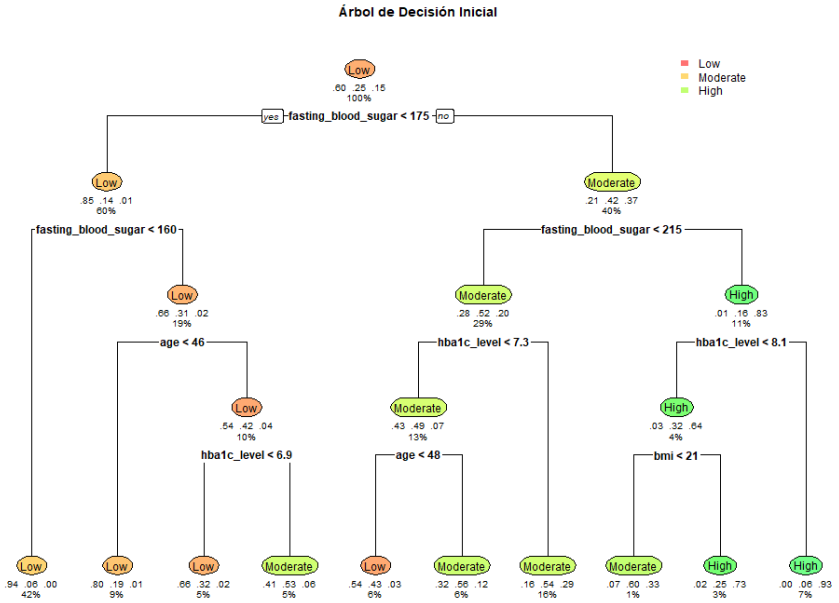




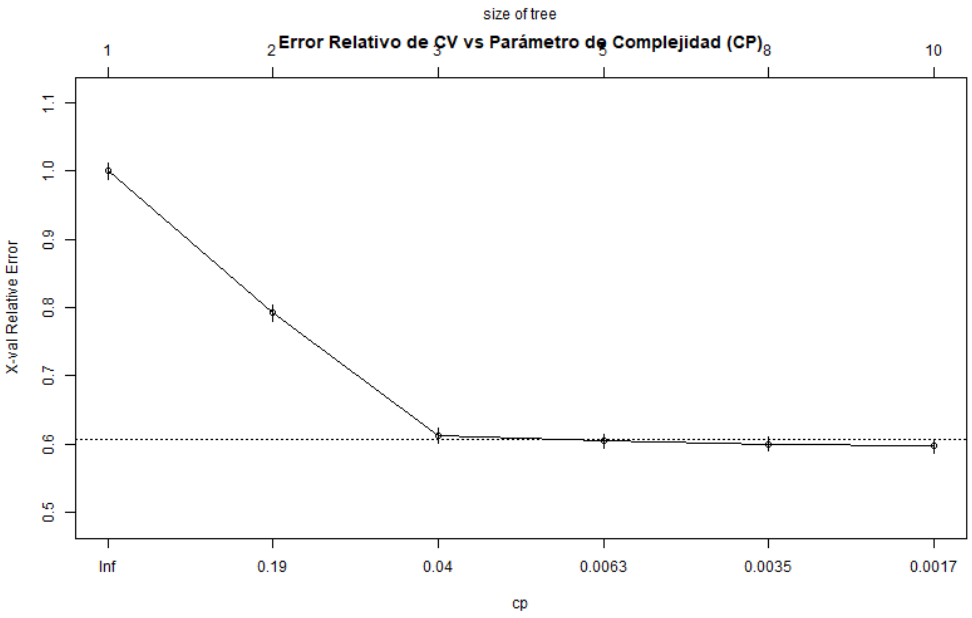
3. Modelado (Modeling)

Desarrollo del Árbol de Decisión

Se ajustó un modelo de árbol de clasificación.



- **Validación Cruzada y Poda:** Se determinó el parámetro de complejidad óptimo minimizando el error relativo de validación cruzada. El árbol podado define las reglas de decisión óptimas para la clasificación.



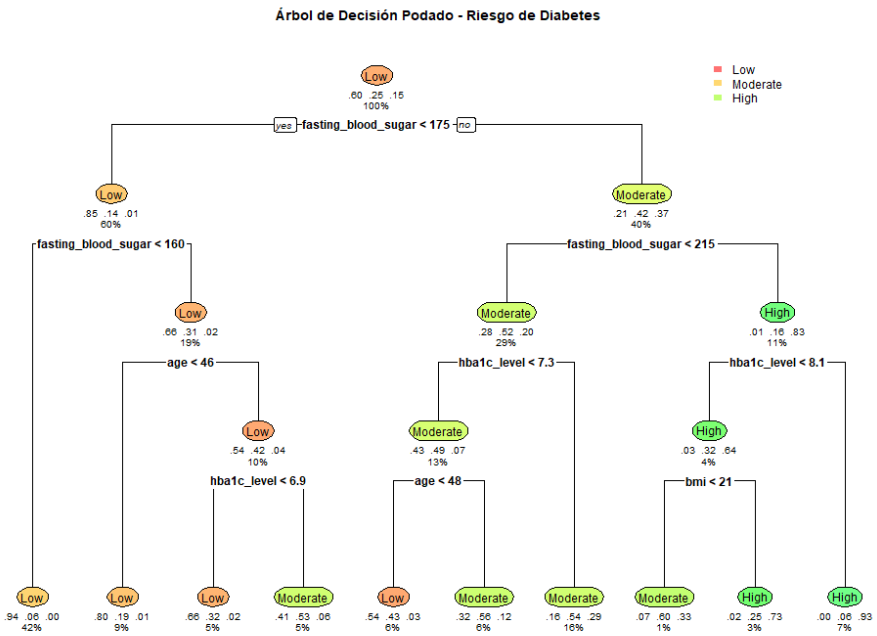
Evaluación del Modelo

Los resultados sobre el conjunto de prueba (4,500 registros) arrojaron las siguientes métricas globales:

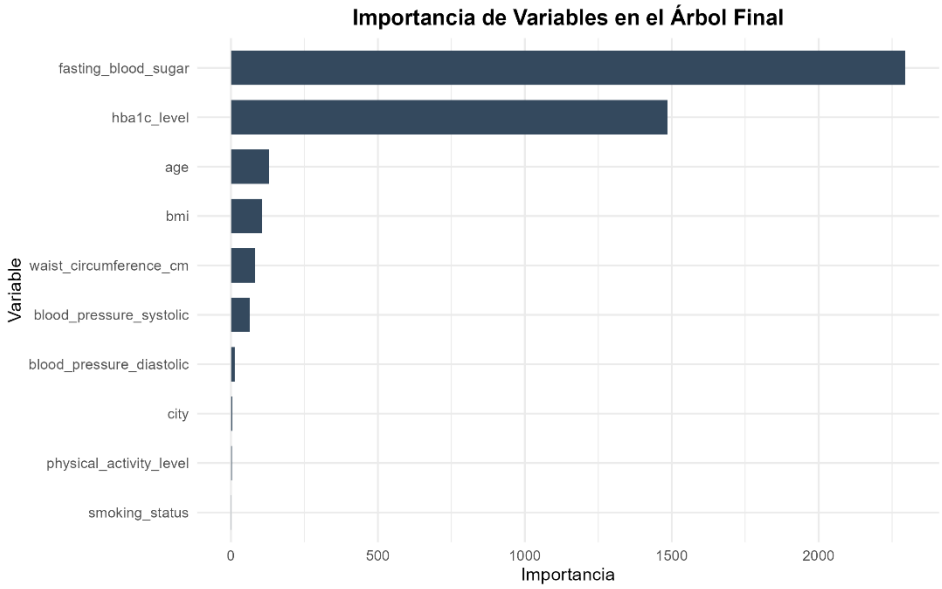
- **Accuracy:** 76.2% (Intervalo de confianza 95%: 74.93% - 77.44%).
- **Índice Kappa:** 0.5569.
- El valor *p* de la prueba de McNemar (< 2.2e-16) indica que el modelo es estadísticamente superior al No Information Rate (60%).

Rendimiento por Clase

- **Clase Low:** Mayor sensibilidad (89.81%) y alta precisión general (Balanced Accuracy: 82.88%).
- **Clase High:** Excelente especificidad (98.32%), indicando una gran capacidad para evitar falsos positivos en el nivel más grave. Sensibilidad del 52.88%.
- **Clase Moderate:** Mantiene el mayor reto de clasificación debido al solapamiento natural con los casos leves y graves (Sensibilidad: 57.51%, Valor Predictivo Positivo: 52.99%).



Dentro de este mismo análisis se demostró que las variables “fasting_blood_sugar” y “hba1c_level” son las variables predictoras mas determinantes para los factores de riesgo.



4.Implementación (Deployment)

El modelo final podado ha sido serializado como un artefacto listo para ser integrado en una aplicación clínica de escritorio para predicciones en tiempo real.

Como equipo, nos asignamos roles específicos dentro de esta metodología para llevar a cabo acciones y concluir con los datos dentro de nuestra base.

Utilizamos R para generar un código donde este mismo pudiera crear carpetas de los gráficos con los que trabajamos visualmente para apoyarnos, para que al generarlos se guardaran los gráficos fuera de R, en una carpeta de documentos, facilitando la manipulación y asegurando el guardado de información de este mismo

otra versión

Utilizamos R para procesar y analizar la información de este mismo riesgo de diabetes dentro de estas variables. Ya que TDSP es un enfoque más estructurado para equipos, por esto mismo nos asignamos roles específicos para poder abarcar todas las fases necesarias dentro de esta metodología.

Dentro de este mismo usamos un código para poder generar y guardar al mismo tiempo los gráficos generados, pero fuera de R, creando una carpeta llamada gráficos dentro del escritorio, y se hizo de esta manera para hacer uso de su manipulación más sencilla, y que todos los integrantes puedan acceder a este tipo de información más fácil.

5. Aceptación del Cliente (Customer Acceptance)

TDSP nos permitió estandarizar el proceso de el dato crudo hasta un modelo desplegable

- **Validación:** El modelo demuestra un alto rendimiento para descartar correctamente casos graves (High) e identificar casos leves (Low).
- **Plan de Acción Iterativo:** Dado el rendimiento en la clase Moderate, la siguiente iteración en el ciclo de vida del TDSP contemplará probar técnicas de ensamble para afinar las fronteras de decisión en los casos intermedios.

Concluimos que el modelo es clínicamente viable como una herramienta de descarte rápida para riesgos bajos y como confirmación para riesgos altos.

6. Referencias

Aggarwal, M. (s. f.). *Diabetes risk prediction*. Kaggle. https://www.kaggle.com/datasets/mansiaggarwal88/diabetes-risk-prediction

Microsoft. (2017). *Team Data Science Process (TDSP)*. Microsoft Learn. https://learn.microsoft.com/es-es/azure/architecture/data-science-process/overview

R Core Team. (2023). *R: A language and environment for statistical computing*. R Foundation for Statistical Computing. https://www.R-project.org/

Therneau, T., Atkinson, B., & Ripley, B. (2023). *rpart: Recursive Partitioning and Regression Trees* (R package version 4.1.21). https://CRAN.R-project.org/package=rpart

Aggarwal, M. (s. f.). *Diabetes risk prediction*. Kaggle. https://www.kaggle.com/datasets/mansiaggarwal88/diabetes-risk-prediction